

Bayes Theorem과 Sigmoid와 Softmax 사이의 관계

Bayes Theorem

Likelihood / Class-conditional Data Distribution

$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}$$

Posterior (사후 확률) ←

← Likelihood / Class-conditional Data Distribution

Prior (사전 확률) →

Evidence 확률의 marginal 특징에 의해

$$P(X) = \sum_j P(X|Y_j)P(Y_j)$$

X : data

Y : Classification 문제의 Class

Prior : 위의 class 들의 분포가 어떻게 되어 있는지에 대한 사전 지식

$P(X|Y)$: 각 class에 속해 있는 data의 확률 분포

$P(Y|X)$: 새로운 data가 들어왔을 경우 Y의 분포 → 어떤 class Y에 속할 지 정할 수 있음

Logistic Function : 2-Class Classification

- 분류를 하고자 할 경우 → 새로운 data를 분류할 때 ⇒ Posterior(사후 확률)을 기준으로 삼음!

$$\left. \begin{array}{l} X : Y_1 \text{ if } P(Y_1|X) > P(Y_2|X) \\ X : Y_2 \text{ if } P(Y_1|X) < P(Y_2|X) \end{array} \right\} \text{ 1과 2 두개의 class}$$

⇒ 판별 기준 Posterior

$$P(Y_1|X) = \frac{P(X|Y_1)P(Y_1)}{P(X)}$$

$$P(Y_2|X) = \frac{P(X|Y_2)P(Y_2)}{P(X)}$$

$$P(X) = P(X|Y_1) + P(X|Y_2)P(Y_2)$$

⇒ Posterior : likelihood와 Prior의 곱이 결정!

⇒ 각 class 별로 likelihood와 Prior의 곱을 정의하는 것은 의미가 있음!

Logistic Function : 2-Class Classification

- Likelihood와 Prior의 곱 정의 $a_k = \ln(P(X|Y_k)P(Y_k))$

Log 붙이는 이유 -> log likelihood

- Log : 단조 증가 함수 \rightarrow 극점 변화 X
- 각 시행이 독립일 경우 \rightarrow 곱에 덧셈으로 바뀜 \Rightarrow 계산 용이
- 확률 분포가 Gaussian 등의 Exponential Family의 경우 \rightarrow 계산 용이

- Class 1 Posterior
$$P(Y_1|X) = \frac{P(X|Y_1)P(Y_1)}{P(X|Y_1)P(Y_1) + P(X|Y_2)P(Y_2)} = \frac{e^{a_1}}{e^{a_1} + e^{a_2}}$$

분모와 분자를 모두 분자로 나누면
$$P(Y_1|X) = \frac{1}{1 + e^{a_2 - a_1}}$$

$$a_2 - a_1 = \ln\left(\frac{P(X|Y_2)P(Y_2)}{P(X|Y_1)P(Y_1)}\right)$$

$$a = -(a_2 - a_1) = \ln\left(\frac{P(X|Y_1)P(Y_1)}{P(X|Y_2)P(Y_2)}\right) \leftarrow \text{이를 Log Odds라 부름}$$

Logistic Function : 2-Class Classification

- Posterior 새롭게 정의 $P(Y_1|X) = \frac{1}{1 + e^{-a}}$

위 식을 a 에 대한 함수로 그려 보면
→ sigmoid function(정식 명칭 : logistic function)
- Naïve Bayes 예로 → 보통 likelihood를 Gaussian으로 정의
⇒ 한 class 내에서 확률 분포 : 평균과 분산을 가지는 Gaussian 적합
Prior의 경우 : 두 가지 중 선택의 문제 → Bernoulli 적합
- Log odds : 해당하는 부분에 위의 분포 대입 Naïve Bayes 분류기 ⇒ Generative Model
- Log odds : likelihood와 Prior의 확률 분포 구분 $X \rightarrow P(Y_1|X) = \frac{1}{1+e^{-\theta x}}$ fitting problem
⇒ Logistic Regression : 대표적인 discriminative problem

Softmax Function : K-Class Classification

- 2-Class → K-Class 확대
$$P(Y_1|X) = \frac{P(X|Y_1)P(Y_1)}{P(X|Y_1)P(Y_1) + P(X|Y_2)P(Y_2) + \dots + P(X|Y_k)P(Y_k)}$$

앞에서 정의한 것 대입
$$P(Y_1|X) = \frac{e^{a_1}}{e^{a_1} + e^{a_2} + \dots + e^{a_k}} = \frac{e^{a_1}}{\sum_j e^j}$$

⇒ Softmax Function

- Normalization Term(분모) → 한 class의 확률이 다른 class에 영향
Generative Model(Naïve Bayes / Gaussian Discriminant Analysis 등) → Prior P(Y)에도 영향!
- Prior 고려 없이 바로 P(Y|X) fitting ⇒ Softmax Regression(Discriminant Model)

$$P(Y|X) = \frac{e^{\theta_1 x}}{\sum_j e^{\theta_j x_j}}$$